BI-VWM

Faginův Top-K Algoritmus

BI-VWM Semestrální práce

Jan Černý
cernyj87@fit.cvut.cz

Obsah

1 Popis projektu

Cílem bylo implementovat Faginův Top-K algoritmus na vyhledání nejlepších K výsledků v databázi produktů. Uživatel si pomocí webového rozhrazní zvolí, podle jakých parametrů chce produkty řadit. Výstupem je tabulka seřazených výsledků, změřený čas běhu algoritmu a počet, kolik bylo provedeno požadavků na databázi.

Projekt obsahuje jak Faginův Top-K, tak i naivní algoritmus sekvenčním průchodem. Je tak možné vyzkoušet rozdílné přístupy a porovnat jejich efektivitu.

2 Způsob řešení

2.1 Databáze produktů

Pro zjednodušení práce s daty jsou využívány CSV soubory, není tak potřeba spouštět žádný databázový engine nebo vytvářet SQL dotazy. Na ukázku jsem si jako produkt vybral počítačové myši, které mají parametry jako název, cenu, váhu, DPI nebo přesnost senzoru.

Ukázková data jsou uložena ve složce `~/data`

- `~/data/mouse.csv` - Ukázková reálná data (cca 40 položek)
- `~/data/test.random.csv` - Náhodně generovaná data (cca 1 milion položek)

2.2 Zpracování dat

Data jsou při načtení uložena do paměti RAM a předtříděna podle parametrů produktu. Jsou znormalizována do rozsahu 0–1, aby každý parametr produktu měl při vyhledávání stejnou váhu. Pokud bychom například využili jako agregační funkci sumu a měli parametry cenu (s rozdíly tisíců Kč) a váhu (s rozdíly několika jednotek gramů), ovlivňoval by rozsah cen výsledek více než rozsah vah.

3 Implementace

3.1 Použité technologie

Aplikace je napsaná v programovacím jazyce Python. Ten jsem zvolil kvůli jeho jednoduchosti, a protože bych se s ním chtěl naučit více pracovat.

Pro webové rozhraní používám Pythonní balíček Gradio, se kterým jsem se setkal jako uživatel primárně u různých aplikací využívající strojové učení. Vybral jsem si ho, protože mě zaujal svojí jednoduchostí na programování, bohužel realita byla spíše opak. Dokumentace obsahuje zatím neimplementované nebo nefunkční vlastnosti a příliš materiálů/návodů online není. Příště bych zvolil spíše Flask na vytvoření REST API a frontend tvořil zvlášť například pomocí NuxtJS, se kterým mám zkušenosti.

3.2 Rozdělení aplikace

Hlavním vstupním bodem je soubor `~/main.py `, který spouští webové rozhraní ze souboru `~/src/app.py`, ve kterém je definované UI aplikace.

Prvním krokem je načtení a předzpracování dat, o to se stará `~/src/Database.py`. Nabízí metody na získání předtříděných seznamů parametrů či celou datovou sadu.

Soubor `~/src/Alhorithm.py` obsahuje statické metody (@classmethod) pro naivní a top-k algoritmy, agregační funkce a další podpůrné funkce.

3.3 Top-K algoritmus

Top-K algoritmus využívá předtříděné seznamy parametrů ze třídy `Database ` a množinu (set) produktů. Python pro množiny používá hashování, díky čemuž je zajištěn konstantní O(1) přístup.

Postupně prochází předtříděné seznamy parametrů a doplňuje ostatní hodnoty parametrů produktu, dokud nezíská „k“ produktů se všemi parametry doplněnými. Následně spočítá výsledné hodnocení pomocí agregační funkce a podle něj seřadí výstupní seznam.

3.4 Sekvenční průchod (naivní algoritmus)

Sekvenční průchod prochází celou databázi produkt po produktu a každému počítá hodnocení pomocí agregační funkce. Seznam následně pomocí něj seřadí a vrátí prvních „k“ výsledků.

4 Spuštění aplikace

Pro spuštění je potřeba mít nainstalovaný Python.

Aplikace využívá další podpůrné balíčky, proto je vhodné si nejdříve vytvořit virtuální prostředí, například do složky `~/.venv` příkazem:

```
python -m venv .venv
```

A aktivovat jej

(PowerShell)	`.venv\Scripts\Activate.ps1`
(CMD)	`.venv\Scripts\activate.bat`
(Bash)	`source .venv/Scripts/activate`

Nainstalovat balíčky (závislosti)

```
pip install -r requirements.txt
```

Samotnou aplikaci lze spustit příkazem

```
python main.py
```

Webové rozhraní poté běží na adrese

http://127.0.0.1:7860/

5 Ukázka aplikace

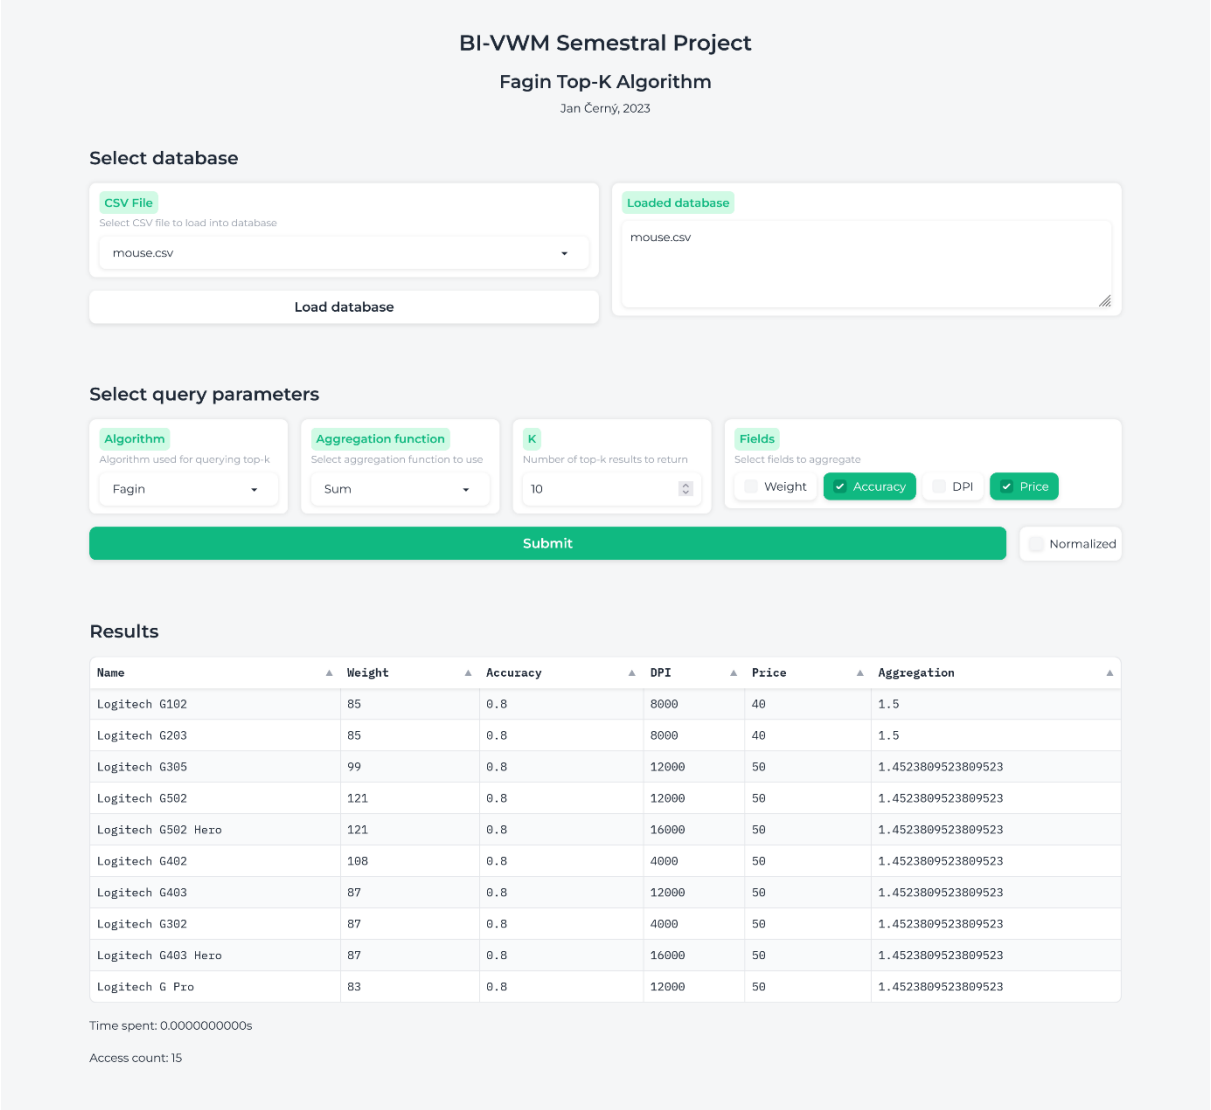

6 Experimenty

V následujících experimentech se pokusím porovnat Faginův algoritmus oproti sekvenčnímu průchodu. Testy byly prováděny na datové sadě o velikosti 1 milion produktů s vybranými všemi čtyřmi parametry.

6.1 Počet přístupů do databáze

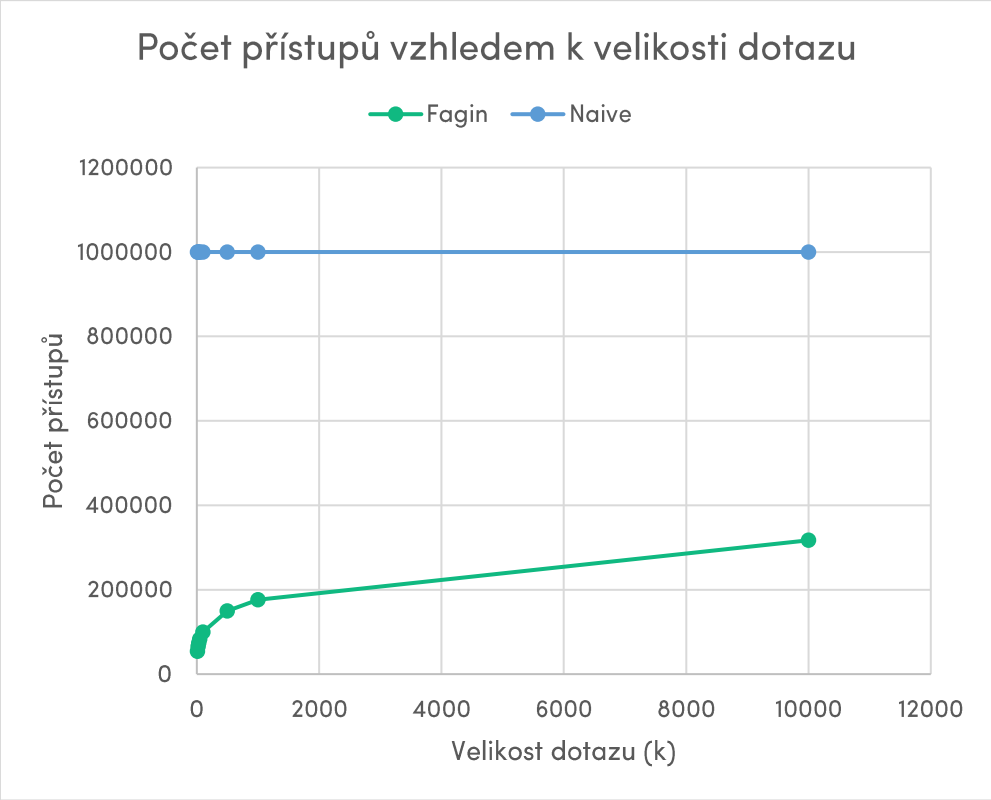

Počet přístupů Faginova algoritmu je závislý na velikosti dotazu (číslo „k“), protože nepotřebuje projít celý dataset, ale skončit, jakmile má všechny parametry pro dostatek produktů. Sekvenční průchod musí vždy projít celý dataset.

6.2 Doba běhu

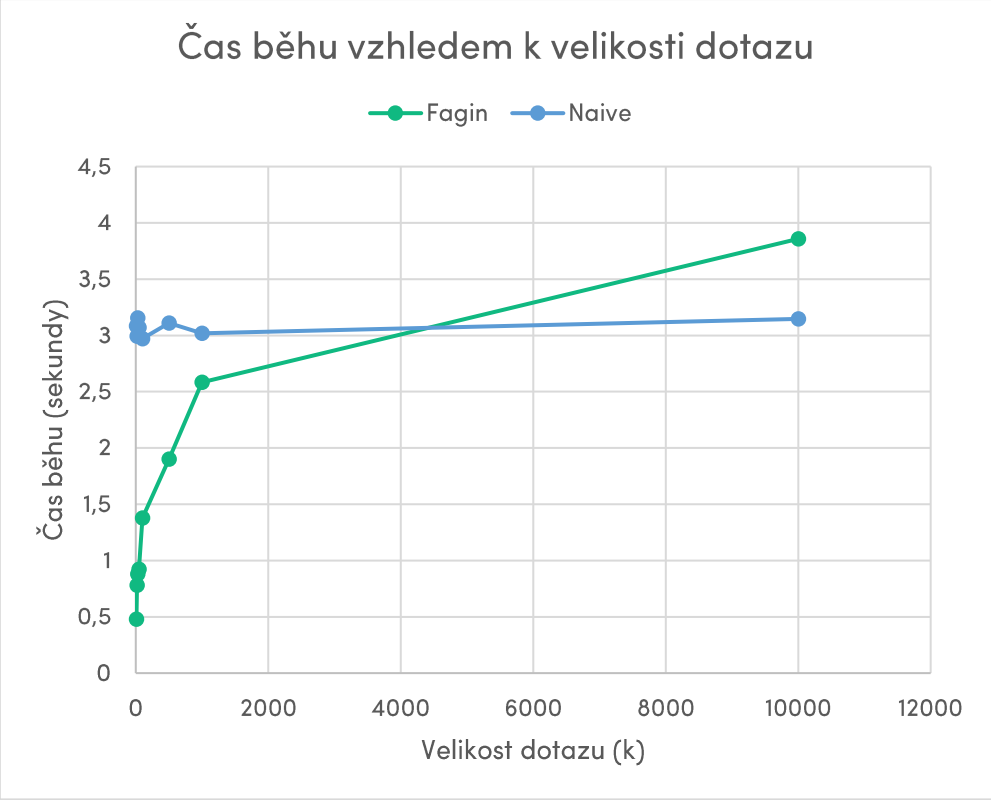

Ačkoliv Faginův algoritmus vyžaduje nižší počet přístupů do databáze, je výpočetně náročnější dohledávat hodnoty zbývajících parametrů produktu. Od určité větší velikosti „k“ se více vyplatí použít sekvenční průchod. Pro nízké „k“ je ale velmi efektivní.

6.3 Počet parametrů

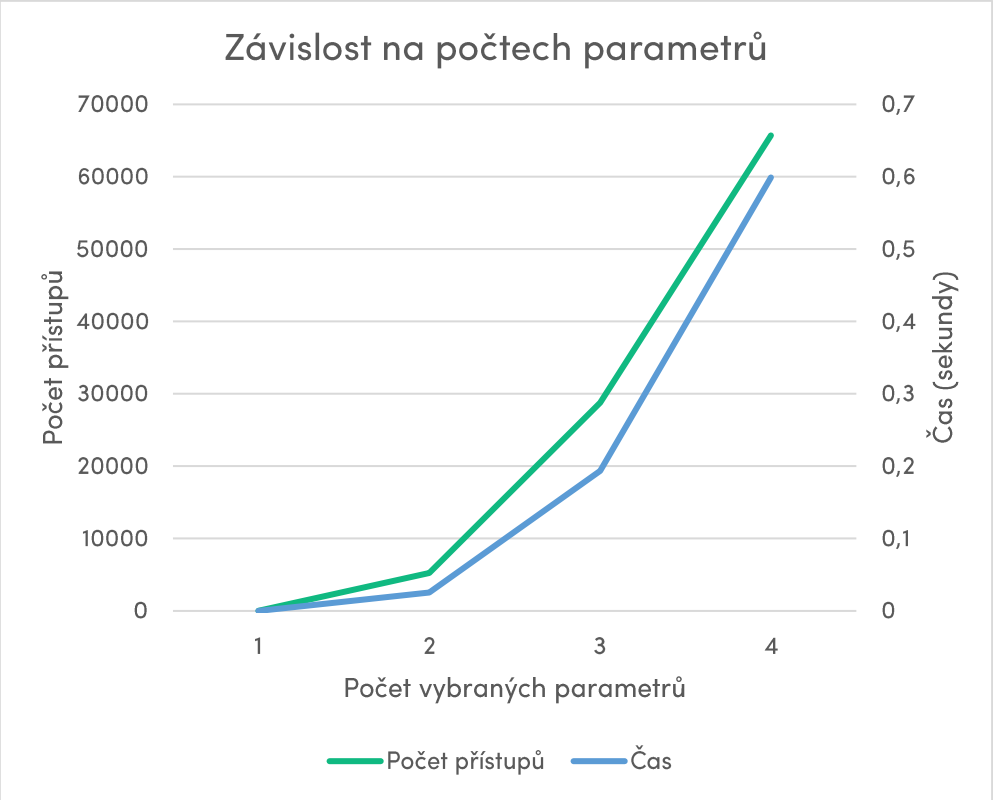

Na tomto grafu nejsou porovnávány algoritmy mezi sebou, ale porovnává pouze vlastnosti Faginova algoritmu. Zkoušel jsem, jak se bude chovat pro různý počet zvolených parametrů. Na grafu je vidět, že počet přístupů do databáze i čas běhu jsou závislé na tomto výběru, protože čím více parametrů je zvoleno, tím více musí algoritmus dohledávat další hodnoty parametrů produktu.

7 Diskuze

Tento projekt obsahuje vlastní implementaci Faginova algoritmu. Pro použití v reálném světe by ji bylo vhodné více otestovat a vyladit případné chyby postihující efektivitu. Implementace byla zjednodušena načítáním dat do paměti, není použit žádný databázový engine. V reálném světe by bylo potřeba předzpracování, normalizace a řazení dat potřeba zakomponovat do datové vrstvy aplikace. Další časová optimalizace by byla možná například použitím kompilovaného C++ místo interpretovaného Pythonu, datová optimalizace použitím pointerů a efektivnějších datových struktur.

8 Závěr

Mým cílem bylo implementovat Faginův Top-K algoritmus. O tomto a dalších podobných algoritmech jsem dříve vůbec neslyšel, proto bylo zajímavé je poznat a něco se o nich naučit. Vyzkoušel jsem si práci s knihovnou Gradio, u které jsem byl z DX[1] lehce zklamán, ale nové znalosti mi přijdou velmi přínosné pro tvorbu web UI v Pythonu.

[1] Developer Experience